

Devoir 1 rapport théorique :

1.

$$a) P(X|Y) = \frac{P(X,Y)}{P(Y)}$$

b)

Soit X = "obtenir exactement 2 faces"

Y = "obtenir face au premier lancer"

$$P(X|Y) = \frac{1}{5} \times \frac{4}{5} + \frac{4}{5} \times \frac{1}{5} = .32$$

c)

$$i) P(X,Y) = P(Y|X) \times P(X)$$

$$ii) P(X,Y) = P(X|Y) \times P(Y)$$

d)

$$\text{D'après c)} \quad P(X,Y) = P(Y|X) \cdot P(X) = P(X|Y) \cdot P(Y)$$

$$\Rightarrow P(X|Y) = \frac{P(Y|X) \cdot P(X)}{P(Y)}$$

e)

$$i) P(\text{McGill}) = 1 - .56 = .44$$

ii)

$$P(\text{McGill} | \text{Bilingue}) = \frac{P(\text{McGill}, \text{Bilingue})}{P(\text{Bilingue})}$$

$$P(\text{McGill}, \text{Bilingue}) = P(\text{Bilingue} | \text{McGill}) \cdot P(\text{McGill})$$

$$= .4 \times .44 = .176$$

$$P(\text{Bilingue}) = P(\text{Bilingue}, \text{McGill}) + P(\text{Bilingue}, \text{UdeM})$$

$$= .176 + .7 \times .56 = .568$$

$$\Rightarrow P(\text{McGill} | \text{Bilingue}) = \frac{.176}{.568} = .31$$

2.

$$a) P(\text{goal} | \text{politique}) = \frac{12}{1000} = .012$$

b) soit N = nombre fois où le mot «congrès» apparaît dans un document de 1000 mots sachant que le sujet est le sport

$$N \sim \text{Binomial}(1000, 4/1000)$$

$$\text{on a: } E(N) = 1000 \times 4/1000 = 4$$

c)

$$P(\text{goal}) = P(\text{goal}, \text{sport}) + P(\text{goal}, \text{politique})$$

$$\begin{aligned} P(\text{goal}, \text{sport}) &= P(\text{goal} | \text{sport}) \times P(\text{sport}) \\ &= \frac{4}{100} \times \frac{1}{3} = .013 \end{aligned}$$

$$P(\text{goal}, \text{politique}) = P(\text{goal} | \text{politique}) \times P(\text{politique})$$

$$= \frac{12}{1000} \times \frac{2}{3} = .008$$

$$P(\text{goal}) = .013 + .008 = .021$$

d)

$$P(\text{sport} | \text{kick}) = \frac{P(\text{kick} | \text{sport}) \times P(\text{sport})}{P(\text{kick})}$$

$$P(\text{kick}) = P(\text{kick}, \text{sport}) + P(\text{kick}, \text{politique})$$

$$P(\text{kick}, \text{sport}) = \frac{15}{100} \times \frac{1}{3} = .05$$

$$P(\text{kick}, \text{politique}) = \frac{2}{1000} \times \frac{2}{3} = .0013$$

$$P(\text{kick}) = .0013 + .05 = .0513$$

$$P(\text{sport} | \text{kick}) = \frac{.05}{.0513} = .975$$

e)

Étant donné que les mots dans un document sont indépendants on a :

$$P(\text{goal}, \text{congress}) = P(\text{goal}, \text{congress}, \text{sport}) + P(\text{goal}, \text{congress}, \text{politique})$$

$$= P(\text{goal}, \text{congress} | \text{sport}) \times P(\text{sport})$$

$$+ P(\text{goal}, \text{congress} | \text{politique}) \times P(\text{politique})$$

$$= P(\text{goal} | \text{sport}) \times P(\text{congress} | \text{sport}) \times P(\text{sport})$$

$$+ P(\text{goal} | \text{politique}) \times P(\text{congress} | \text{politique})$$

$$\times P(\text{politique})$$

$$= \frac{4}{100} \times \frac{4}{1000} \times \frac{1}{3} + \frac{12}{1000} \times \frac{6}{100} \times \frac{2}{3}$$

$$= 5.33 \times 10^{-4}$$

$$P(\text{congress}) = P(\text{congress} | \text{sport}) \times P(\text{sport})$$

$$+ P(\text{congress} | \text{politique}) \times P(\text{politique})$$

$$= \frac{4}{1000} \times \frac{1}{3} + \frac{6}{100} \times \frac{2}{3} = .041$$

$$\Rightarrow P(\text{goal} | \text{congress}) = \frac{P(\text{goal}, \text{congress})}{P(\text{congress})}$$

$$P(\text{goal} | \text{congress}) = \frac{5.33 \times 10^{-4}}{.041} = .013$$

f)

Pour estimer par exemple $P(\text{goal} | \text{politique})$ on compte le nombre total de fois que le mot "goal" apparaît dans tous les documents de type "politique" puis on le divise par le nombre total de mots dans tous les documents de type "politique".

Pour estimer par exemple $p(\text{politique})$
on compte le nombre total de documents
de type "politique" ensuite on le divise par N .

3.

a)

soit $\underline{n} = (n_1, n_2, \dots, n_n)$

$$\text{on a : } f_{\theta}(\underline{n}) = f_{\theta}(n_1) \times f_{\theta}(n_2) \times \dots \times f_{\theta}(n_n)$$

b)

$$\text{on a : } f_{\theta}(\underline{n}) = \prod_{i=1}^n f_{\theta}(n_i) = \prod_{i=1}^n \frac{1}{\theta} = \frac{1}{\theta^n}$$


$$\frac{\partial}{\partial \theta} f_{\theta}(\underline{n}) = -n \theta^{-n-1} < 0 \quad \forall \theta \geq 0$$

alors la vraisemblance est une fonction
décroissante sur θ donc elle est maximale
pour des petites valeurs de θ

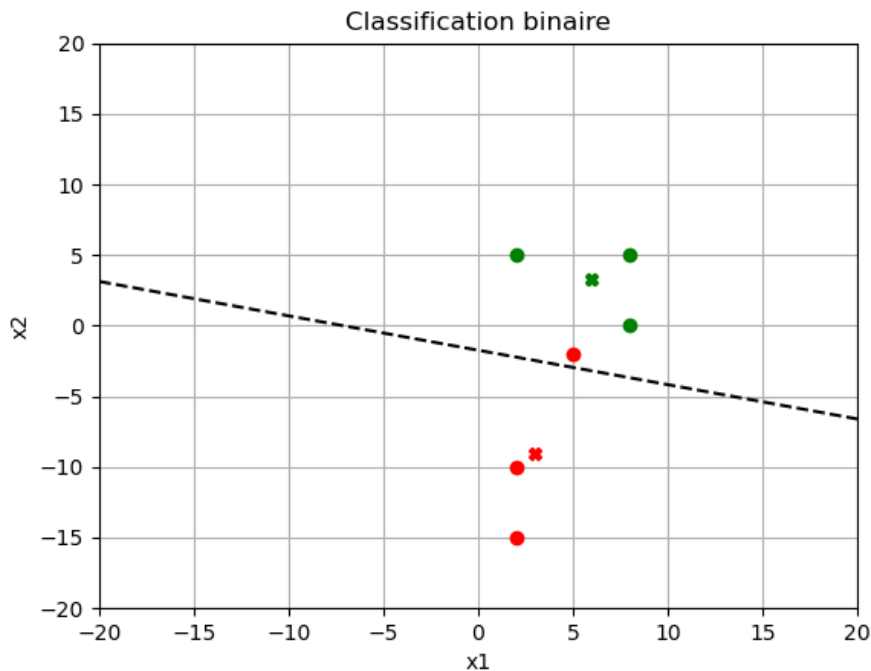
Etant donné que θ doit toujours être plus
grande que les observations on en

3) déduit que la plus petite valeur que $\hat{\theta}$ peut prendre est le maximum des observations
 d'où $\hat{\theta} = \max \{x_1, x_2, \dots, x_n\}$


4.
 a)



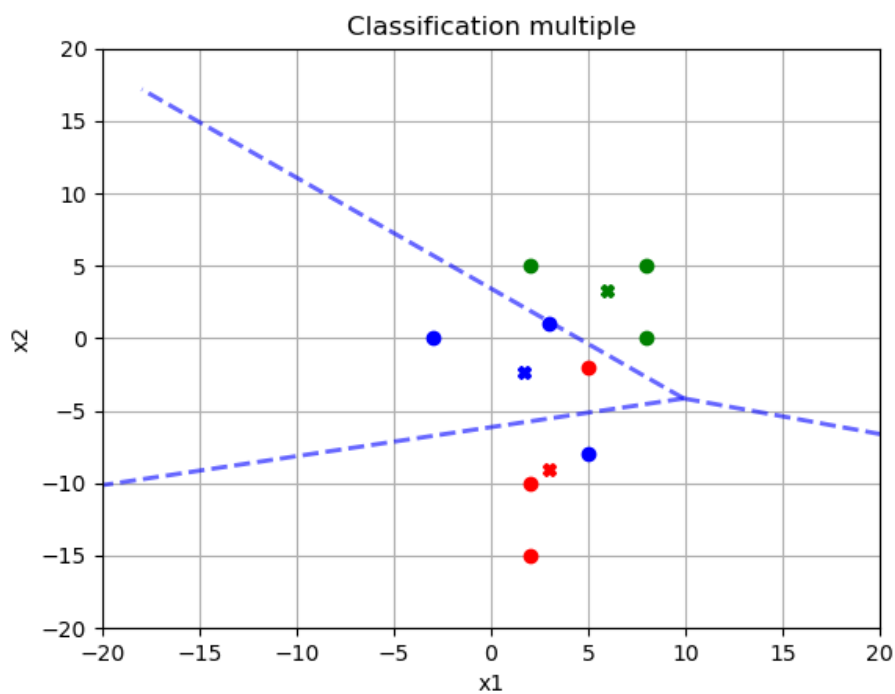
b)



c)



d)



a)

$$\text{on a: } 1_{\{x \in S\}} = \begin{cases} 1 & \text{si } x \in S \\ 0 & \text{sinon} \end{cases}$$

alors $E[1_{\{x \in S\}}] = 1 \times P(x \in S) + 0 \times P(x \notin S)$

$$\Rightarrow E[1_{\{x \in S\}}] = P(x \in S)$$

b)

Soit $Y_j = 1_{\{X_j \in V_i\}}$

on a: $E(Y_j) = E[1_{\{X_j \in V_i\}}] = P(X_j \in V_i)$

$$= \int_{V_i} f(x) dx \quad \text{pour } x_j \text{ continue}$$

Supposons que $\{X_j\}_{j=1}^n$ est iid alors les

Y_i sont aussi iid en tant que fonctions de variables iid.

Soit $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$.

Par la loi des grands nombres \bar{Y}_n converge

en probabilité vers $E(Y_i) = \int_{V_i} f(x) dx$.

Le résultat devient immédiat en

remarquant que $\hat{p}(x_j \in V_i) = \bar{Y}_n$

c)

Nombre total de régions = 2^{464}

Nombre de chiffres = $\left\lfloor \log_{10}(2^{464}) \right\rfloor + 1 = 140$

d)

plus petit nombre = $16 \times 4 \times 2^{464}$
 $= 3.05 \times 10^{141}$

e)

Soit R une certaine région

n

on a: $P(R \text{ soit vide}) = \left(1 - \frac{1}{m^d}\right)^n$

Sachant que chaque dimension est subdivisée en d régions, nous avons m^d régions au total en d dimensions.

Si les points sont uniformément répartis sur toutes les régions alors tous les points ont la même chance d'appartenir à une région qui est égal à

$$\frac{1}{\# \text{ total de régions}} = \frac{1}{m^d}$$

Donc $P(R \text{ soit vide}) = P(\text{tous les points} \notin R)$

$$= \prod_{i=1}^n P(\text{point } i \notin R) = \prod_{i=1}^n \left(1 - \frac{1}{m^d}\right) = \left(1 - \frac{1}{m^d}\right)^n$$